
Weight-Freezing: 一种全连接层的正则化方法及其在脑电分类中的应用

苗政清 *

赵美蓉 *

Abstract

在脑电解码领域, 提升人工神经网络 (ANNs) 性能具有重要的潜力。本研究引入一种新方法, 称为 “Weight-Freezing”, 它基于 ANN 正则化和神经科学的先验知识原理。Weight-Freezing 的概念围绕着在反向传播过程中冻结全连接层中特定权重, 以减少某些神经元对特定脑电任务决策过程的影响。通过使用掩码矩阵和阈值确定在反向传播过程中冻结权重的比例来实现这一目标。此外, 通过将掩码权重设置为零, Weight-Freezing 不仅可以在具有全连接层作为分类器的网络中实现稀疏连接, 还可以作为全连接层的一种有效的正则化方法。通过针对三种不同的 ANN 架构和三个广为认可的脑电数据集的实验证明了 Weight-Freezing 的效能。我们的方法在所有测试数据集中显著超越了先前的最佳分类准确率。附加的对照实验提供了在实施 Weight-Freezing 前后的性能差异的见解, 并对 Weight-Freezing 过程中阈值的影响进行了详细分析。我们的研究强调了 Weight-Freezing 相对于传统的全连接网络在脑电特征分类任务中的卓越效果。凭借其已被证实的有效性, 这种创新方法在未来的脑电解码研究中具有重要的潜力。

Keywords 正则化 · 脑机接口 (BCI) · 脑电图 (EEG) · 分类器 · 神经网络

1 引言

脑电图 (EEG) 因其无创性、高时域分辨率、便携性和成本效益而被广泛应用于脑机接口 (BCI) 系统 (Wolpaw (2007); Michel and Murray (2012))。例如, 运动想象 (MI) 信号 (Lotze and Halsband (2006)) 是一类在没有实际物理运动的情况下由个体想象执行运动任务时产生的 EEG 信号子集, 对于 BCI 应用来说尤为有趣, 因为它们可以用于运动康复和脑功能调控 (Pfurtscheller and Neuper (2001); Park et al. (2014); Stermann (1996))。然而, 由于 EEG 的低空间分辨率、低信噪比以及脑活动的非平稳性和固有变异性, 准确识别与 EEG 信号对应的脑活动是具有挑战性的 (Kaplan et al. (2005); Goncharova et al. (2003))。常用的空间模式 (CSP) 及相关方法 (Lotte and Guan (2010); Ang et al. (2011)) 是用于 MI 中的特征提取的机器学习技术。它们从 EEG 信号中识别与特定任务相关的最优通道和特征。其中, 滤波器组共享空间模式 (FBCSP) 通过将一组带通滤波器应用于原始 EEG 数据, 为每个滤波器带生成特定频谱的信号, 对 MI 信号的特征提取起到重要作用 (Ang et al. (2008))。

鉴于人工神经网络 (ANN) 具有强大的特征提取和分类能力, 它们正在成为 BCI 应用中解码 EEG 信号的热门选择 (Schwemmer et al. (2018); Acharya et al. (2018))。例如, Schirrmeister 等人 (2017) 探索了 Shallow-ConvNet 和 Deep-ConvNet 在 MI 和运动执行 (ME) EEG 信号中的特征提取能力 (Schirrmeister

通讯作者: 苗政清 (mzq@tju.edu.cn)

*天津大学精密仪器与光电子工程学院, 精密测量技术与仪器国家重点实验室, 邮编: 300072

et al. (2017))。Lawhern 等人 (2018) 在 Shallow-ConvNet 解码器中添加了一个时间卷积层, 并使用可分离卷积来提高解码器在各种 EEG 范式下的性能 (Lawhern et al. (2018))。Borra 等人 (2020) 提出了一种轻量级浅层 CNN, 它堆叠了一个时间同步卷积层和一个空间深度卷积层, 以提取高效的 MI 和 ME-EEG 特征 (Borra et al. (2020))。在我们之前的工作中, 我们提出了 LMDA-Net, 它在原始的时域和空域卷积基础上增加了通道注意力模块和深度注意力模块, 以增强各种 BCI 任务的特征提取能力 (Miao et al. (2023))。这些模型都是端到端的人工神经网络, 旨在从特征提取网络的角度增强 ANN 对 EEG 信号的解码能力。然而, 据我们所知, 没有研究过端到端 ANN 中的分类器对 EEG 解码性能的影响。其中一个重要原因可能是机器视觉、自然语言处理或 EEG 解码中分类器的设置相对固定, 通常使用一个或多个全连接层进行分类。这项研究面临的问题是, 对于具有低信噪比和小数据量的 EEG 信号, 现有的全连接网络是否是最优的分类器。

为了探讨这个问题, 本研究提出了一种 Weight-Freezing 技术。顾名思义, Weight-Freezing 在全连接层的反向传播过程中冻结了部分权重。如图1所示, 与全连接网络相比, Weight-Freezing 抑制了全连接网络中一些参数的更新, 从而在分类决策过程中有效地抑制了一些输入神经元对决策结果的影响。

本文的主要贡献如下:

1. 在我们所知, 本文是第一篇研究 ANN 中分类器对 EEG 解码性能影响的论文。为此, 我们提出了 Weight-Freezing 技术, 通过冻结全连接层中的某些参数, 抑制了某些输入神经元对特定决策结果的影响, 从而实现更高的分类准确性。
2. Weight-Freezing 也是一种新颖的正则化方法, 可以在全连接网络中实现稀疏连接。
3. 我们在三个经典解码网络和三个高引用的公开 EEG 数据集上对 Weight-Freezing 进行了全面验证和分析。实验结果验证了 Weight-Freezing 在分类方面的优越性, 并在这三个高引用数据集上取得了最先进的分类性能 (平均所有参与者)。

本研究的主要贡献在于强化了人工神经网络 (ANN) 模型在脑机接口 (BCI) 系统中的应用和实施。同时, 它为将来使用更大模型 (如 transformers Vaswani et al. (2017)) 解码 EEG 信号设定了新的性能基准。最近的研究 (Ahn et al. (2022); Bagchi and Bathula (2022); Zhang et al. (2023); Ma et al. (2023); Song et al. (2023)) 越来越多地采用 transformer 网络进行 EEG 信号解码。这些方法可以视为对现有 ANN 模型的丰富, 通过更复杂的特征提取网络提高 EEG 分类准确性。然而, 这些改进不可避免地使得在真实世界的 BCI 系统中部署这些 ANN 模型变得更加复杂。与之形成鲜明对比的是, 我们的研究引入了 Weight-Freezing 作为一种创新的减法策略来改进现有的 ANN 模型。借助 Weight-Freezing 的增强, 一些轻量级和浅层的解码网络在相同的公开数据集上超越了所有当前基于 transformer 的方法的分类性能。Weight-Freezing 的引入不仅简化了在 BCI 系统中部署 ANN 模型的过程, 还为未来部署更大模型 (如 transformer) 设定了新的性能标准。此外, 它在 EEG 解码领域引发了一个有趣的问题: 在 EEG 特征提取中, 部署大型模型 (如 transformer) 是否真正是必不可少的?

2 动机

2.1 人工神经网络的解码能力

在使用人工神经网络 (ANN) 进行 EEG 信号分类时, 以往的研究主要集中在设计特征提取网络上。例如, Shallow-ConvNet (Schirrmeister et al. (2017)) 利用了基于 EEG 信号特征的时空卷积网络进行特征提取。EEGNet (Lawhern et al. (2018)), DRDA Zhao et al. (2020) 和 Conformer (Song et al. (2023)) 等 ANN 模型认为这两个层的特征提取能力有限, 因此加深了特征提取网络的层数。Sinc-ShallowNet (Borra et al. (2020)) 和 LMDA-Net (Miao et al. (2023)) 则在不加深特征提取网络层数的情况下, 水平扩展了时空卷积的特征提取能力。毫无疑问, 设计针对 EEG 的特征提取网络对于解码 EEG 信号至关重要。然而, 在端到端的 ANN 模型中, 特征提取网络和分类器构成了一个整体系统, 全连接网络对于 EEG 特征分类的优化性仍然是一个问题。




图 1: Weight-Freezing 前后的比较图。(a) 标准的全连接网络。(b) 带有 Weight-Freezing 的全连接层。虚线表示冻结的权重。

本研究采用了不同的角度，通过专注于增强分类器的分类能力来解决 EEG 分类问题。本研究的基本假设是输入分类器的特征中混杂着噪声，这是由 EEG 中的低信噪比和有限的数据可用性引起的。低信噪比意味着信号中存在广泛的噪声，而有限的数据可用性阻碍了 ANN 中特征提取层的有效训练，从而妨碍了噪声对特征提取和分类的影响的消除。

2.2 人工神经网络中的过拟合

在端到端的人工神经网络中，特征提取网络和分类网络构成一个完整的实体。从前向传播和后向传播的角度来看，特征提取网络和分类网络相互补充。EEGNet (Lawhern et al. (2018))、Sinc-ShallowNet (Schirrmeyer et al. (2017)) 和 LMDA-Net (Miao et al. (2023)) 等模型在特征提取网络中采用可分离卷积，使得特征提取网络内部实现了稀疏连接。这种设计在有效避免神经网络模型过拟合的同时，也能有效应对 EEG 中有限的数据量和低信噪比的特点。

尽管用于 EEG 解码的 ANN 在特征提取层的设计上有着显著的差异，但 Shallow-ConvNet、Deep-ConvNet、EEGNet、Sinc-ShallowNet 和 LMDA-Net 都使用全连接层进行分类。因为全连接网络是密集连接的，即当全连接层的输入和输出分别为 n_1 和 n_2 时，全连接层需要引入 $n_1 \times n_2$ 个可学习参数。对于只有几百个训练样本的 EEG 数据来说，这很容易导致过拟合 (Bejani and Ghatee (2021); Santos and Papa (2022); DeVries and Taylor (2017))。这也是上述经典 ANN 仅使用单个全连接网络进行分类的原因。为了最小化全连接层中的过拟合现象，LMDA-Net 采用了三种策略尽量减少输入到全连接层的神经元数量，即在空间卷积层（全连接层之前的层）中使用少量的空间卷积核、自适应池化和较大的丢弃率 ($P=0.65$)。

然而，上述的降采样或正则化方法都是在全连接层之前起作用，目前还没有有效的正则化方法来约束全连接层本身的密集连接。如果将全连接层的密集连接方法改为稀疏连接，将大大减少全连接层中可学习参数的数量，这可能对于数据量较小且信噪比较低的 EEG 信号来说是一个优势。

2.3 神经科学的先验知识

使用全连接层进行 EEG 分类意味着全连接层中的每个神经元都对特定的神经活动类别的决策过程有贡献。这意味着确定特定神经活动的判断需要涉及所有输入神经元。然而，这种决策过程与神经科学的先验知识不一致。例如，在运动意向任务中，激活左手运动意向任务会触发右半球的运动皮层，而激活右手运动意向任务会触发左半球的运动皮层。类似地，激活双脚运动意向任务会触发大脑运动皮层的中央区域 (Pfurtscheller et al. (2006); Pfurtscheller and Neuper (2001))。这一先验知识表明，在确定运动意向的类别时，不必考虑所有神经元的电信号。相反，更符合神经科学先验知识的分类器应仅考虑决策过程中特定输入神经元对类别的影响。换句话说，采用全连接层内的稀疏连接方法更符合神经科学的先验知识。

3 方法

3.1 Weight-Freezing 原理

以单个全连接层为例，我们来探讨 Weight-Freezing 的具体原理和实现方法。假设输入到全连接层的特征为 $X = \{x_1, x_2, \dots, x_n\}$ ，其中 $X \in \mathbb{R}^{N \times L}$ ，这里 N 表示小批量的大小， L 表示特征的维度。设 $n \in \{1, N\}$ 表示网络的小批量索引。 x_n 表示输入到全连接层的向量， y_n 表示全连接层的输出向量， W_n 和 b_n 分别表示全连接层的权重和偏置。全连接层的前向传播操作可以描述为：

$$y_n = W_n x_n + b_n \quad (1)$$

假设全连接层的输出通过交叉熵损失函数进行分类，交叉熵损失函数的输出记为 \mathcal{L} ， z_n 表示目标类别， C 是类别的数量。交叉熵损失函数的输出可以描述为：

$$\mathcal{L} = - \sum_{n=1}^N \log \frac{e^{y_n, z_n}}{\sum_{c=1}^C e^{y_n, c}} \quad (2)$$

在公式1中， W_n 和 b_n 是可学习参数，在训练过程中通过反向传播算法计算的梯度进行迭代调整。训练过程中可学习参数 W_n 的导数如公式3所示：

$$\frac{\partial \mathcal{L}}{\partial W_n} = \frac{\partial \mathcal{L}}{\partial y_n} \cdot \frac{\partial y_n}{\partial W_n} = (\tilde{z}_n - z_n) \cdot x_n^T \quad (3)$$

这里， \tilde{z}_n 表示交叉熵损失函数中 softmax 函数输出的预测值。*

设 η 表示优化器的学习率，则神经网络模型训练过程中参数 W_n 的更新可以表示为：

$$W_n = W_n - \eta \cdot (\tilde{z}_n - z_n) x_n^T \quad (4)$$

上述过程完整地描述了全连接层在前向传播和反向传播中可学习参数 W_n 的作用和更新过程。Weight-Freezing 方法不会改变全连接层的前向传播过程，但在反向传播过程中，顾名思义，它会冻结全连接层中的部分可学习参数，防止它们通过反向传播进行更新。该方法的具体实现可以由公式5表示：

$$W_n = W_n - M \odot (\eta \cdot (\tilde{z}_n - z_n) x_n^T) \quad (5)$$

在公式5中， M 是一个与 W_n 具有相同维度的掩码矩阵，其中的元素遵循在 $[0, 1)$ 范围内的均匀分布。 t ($0 \leq t \leq 1$) 表示掩码矩阵的阈值，较大的 t 表示更高程度的掩码，导致 W_n 中有更多的参数被冻结。 \odot 符号表示逐元素相乘，也称为 Hadamard 乘积。如果一个元素被掩码，则意味着在反向传播过程中它被冻结，无法通过反向传播进行更新。

此外，Weight-Freezing 还可以实现全连接层中的稀疏连接。通过在掩码矩阵 M 中将被掩码的权重手动设为零，被掩码部分在前向传播和反向传播中变为不活跃状态，实现了全连接层的稀疏连接。

*交叉熵损失函数的求导过程在网上广泛可得，这里省略具体的求导过程。

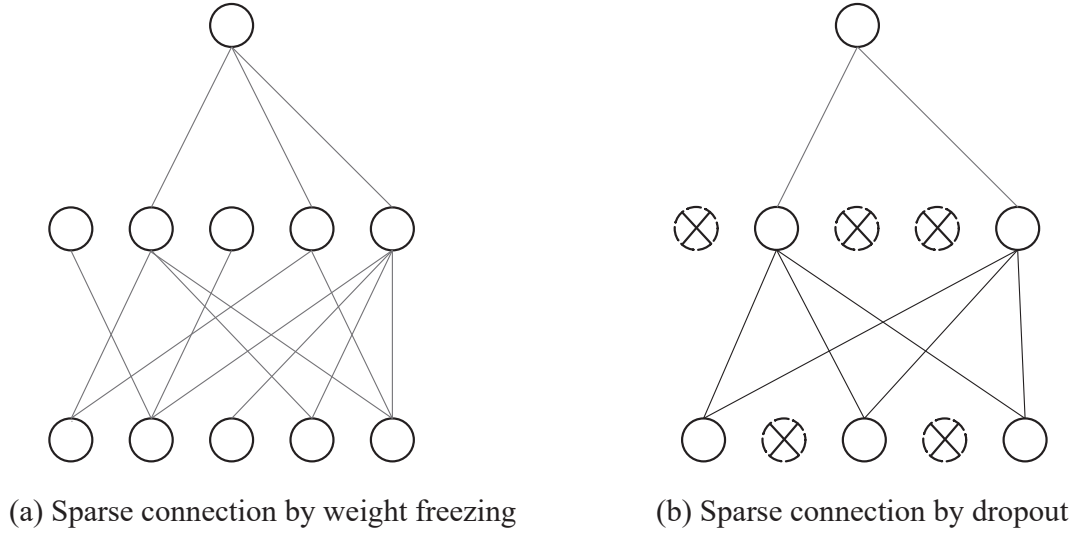


图 2: Dropout 与 Weight-Freezing 在正则化时的区别 (a) 使用 Weight-Freezing 实现正则化 (b) 使用 Dropout 实现正则化

3.2 与 Dropout 的区别

Dropout (Srivastava et al. (2014); Wager et al. (2013); Wu and Gu (2015)) 方法可以用数学表示为公式6:

$$\mathbf{v}_{\text{dropout}} = \mathbf{v} \odot \mathbf{m} \quad (6)$$

在公式6中, \mathbf{v} 表示 Dropout 层的输入向量, \mathbf{m} 是与 \mathbf{v} 具有相同维度的掩码向量。 \mathbf{m} 的元素是独立地从参数为 p 的伯努利分布中抽取的。如果一个元素被抽取到, 对应的神经元将被“丢弃”, 即其输出被设为 0。

Weight-Freezing 和 Dropout 都可以被视为神经网络中的正则化方法, 用于防止过拟合。Weight-Freezing 和 Dropout 的实现原理比较如下:

1. **作用目标:** 从图2可以看出, Dropout 通过改变神经元的状态, 而 Weight-Freezing 通过将掩码部分的可学习参数设为 0 来实现全连接层的稀疏连接。
2. **信息传递:** Dropout 影响前向传播和反向传播, 而 Weight-Freezing 仅影响反向传播。
3. **作用方式:** Dropout 丢弃的神经元完全失去决策能力, 而 Weight-Freezing 仅影响部分神经元的决策能力。
4. **灵活性:** Dropout 和 Weight-Freezing 都可以应用于全连接层。如今, Dropout 也可以应用于非全连接层。此外, 由于 Dropout 和 Weight-Freezing 具有不同的实现原理, 它们可以同时使用。

4 数据集

4.1 数据集 1: MI (BCI4-2A)

BCI4-2A 数据集[†]采用了一个包含 22 个 EEG 通道的 10-20 系统进行采集, 采样率为 250 Hz。该数据集包括来自 9 名健康参与者 (ID A01-A09) 的数据, 跨越两个不同的实验会话。每个参与者被要求进行四种不同的运动想象练习: 想象左手运动、右手运动、双脚运动和舌头运动。每个会话包括 288 个 EEG 数据试验。第一

[†]www.bbc.de/competition/iv/#dataset2a

个会话中采集的数据用于训练，而第二个会话中的数据用于测试。与 Shallow-ConvNet (Schirrmeister et al. (2017)) 使用 MI 提示前 0.5 秒的数据不同，本研究仅选择每个试验的运动想象任务时段进行时域分割，具体而言，选择每个 MI 提示后 [2, 6] 秒的时间段进行分割，除非另有说明。

4.2 数据集 2: MI (BCI4-2B)

BCI4-2B 数据集[†]采用了包含 3 个 EEG 电极通道的配置进行采集，采样率为 250 Hz。该数据集包括来自 9 名健康参与者 (ID B01-B09) 的数据，跨越五个独立的采集会话。每个参与者被要求进行两种不同的运动想象练习：想象左手运动和右手运动。前两个会话每个会话包括 120 个试验，没有反馈；后三个会话每个会话包括 160 个试验，并在屏幕上显示笑脸作为反馈。按照 Miao et al. (2023) 的研究，前三个会话的所有数据用于训练，而最后两个会话的数据用于测试。对于我们的实验，从每个 MI 提示后 [3, 7] 秒的时间段提取一个试验的 EEG 数据作为时域分割。

4.3 数据集 3: ME (High-Gamma)

High-Gamma 数据集[§]来自 14 名健康参与者 (6 名女性，2 名左利手，平均年龄 27 ± 3.6 岁)。每位参与者贡献了大约 1000 个持续 4 秒的运动试验，共分为 13 个运行。该数据集使用了一个包含 128 个 EEG 电极的配置，其中 44 个传

感器覆盖了运动皮层。该数据集是在专门用于非侵入式检测高频运动相关 EEG 成分的实验室中采集的。技术上的设置包括主动电磁屏蔽、高分辨率低噪声放大器、主动屏蔽的 EEG 帽和全光解耦。所有设备均使用电池供电，并通过光纤进行通信。实验涉及四类运动：左手、右手、双脚和休息，由视觉提示触发。每个运行包含 80 个试验，每个试验持续 4 秒，然后是 3 到 4 秒的试验间隔。训练集包括来自除最后两个运行以外的所有运行的大约 880 个试验，而测试集包括来自最后两个运行的大约 160 个试验。该数据集的配置严格遵循 Schirrmeister et al. (2017) 的描述，除了数据预处理方法。

5 实验

5.1 预处理

在进行特征提取和分类之前，对 EEG 信号进行了预处理，包括带通滤波和归一化。预处理方法与我们之前的工作保持一致 (Miao et al. (2022, 2023))。使用 200 阶 Blackman 窗口的带通滤波器对原始 EEG 数据进行滤波。随后，对滤波后的原始 EEG 数据按照每个数据集中任务的持续时间进行分段。

MI 任务的原始 EEG 数据带通滤波到 [4, 38] Hz，ME 任务的原始 EEG 数据带通滤波到 [4, 125] Hz。MI 和 ME 的归一化方法与我们之前的工作保持一致，包括试验归一化和欧几里德对齐 (He and Wu (2019))。预处理方法的具体实现如下：

$$\mathbf{x}_i = \frac{\mathbf{x}_i}{\max(|\mathbf{x}_i|)} \quad (7)$$

$$\bar{\mathbf{R}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^T \quad (8)$$

$$\tilde{\mathbf{x}}_i = \bar{\mathbf{R}}^{-1/2} \mathbf{x}_i \quad (9)$$

其中 i 表示第 i 个试验的 \mathbf{x} ， $|\cdot|$ 表示矩阵取绝对值， N 表示试验的数量。

[†]www.bbc.de/competition/iv/#dataset2b

[§]<https://gin.g-node.org/robintibor/high-gamma-dataset/src/master/data>

5.2 实验环境和参数设置

所有实验都是在配备 Intel(R) Xeon(R) Gold 5117 CPU @ 2.00 GHz 和 Nvidia Tesla V100 GPU 的工作站上使用 PyTorch 框架进行的。所有模型都使用 AdamW (Loshchilov and Hutter (2018)) 作为优化器, 采用默认参数, 并使用大小为 32 的小批量进行训练。

所有实验采用了留出测试数据集的方法。为了确保实验的可重复性, 所有实验中使用了统一的随机数种子。由于数据增强方法可能影响结果的可重复性, 本实验没有选择数据增强方法。同样, 交叉验证方法不仅影响实验结果的可重复性, 而且与 BCI 的实际使用场景有很大的差异, 因此实验部分不考虑交叉验证。为了增强实验结果的可重复性, 本文在所有实验中均没有划分验证集, 而是使用整个训练数据集来训练 ANN 模型, 并记录训练过程中测试集的最高准确率以及特定时刻的平均准确率和中位数准确率等统计数据。

值得注意的是, ConvNet (Schirrmester et al. (2017)) 在 EEG 解码中提供了浅层和深层版本。然而, 浅层 ConvNet 因其在解码中的优势而受到重视。因此, 在我们的实验中, 选择浅层 ConvNet 作为实验模型 (以下简称 ConvNet) 进行比较。

5.3 实验结果

5.3.1 基准算法

在实验中, 我们将 Weight-Freezing 应用于三种不同的 ANN 模型, 并将它们的解码能力与几种经典算法进行比较。FBCSP (Ang et al. (2008)) 是一种用于 MI 和 ME-EEG 特征提取的著名算法, 本研究将其作为手动特征提取方法的代表。ConvNet (Schirrmester et al. (2017)) 和 EEGNet (Lawhern et al. (2018)) 是 2017 年和 2018 年发表的目前在 EEG 解码领域引用较多的 ANN 模型。Sinc-ShallowNet (Borra et al. (2020)) 是 2020 年发表的一种专门设计用于 EEG 解码的轻量级网络, 虽然参数远少于 ConvNet, 但在解码准确性方面可以达到相当水平。DRDA (Zhao et al. (2020)) 也是 2020 年发表的一种利用其他参与者数据增强训练的方法, 在 BCI4-2A 和 BCI4-2B 上的平均解码准确率 (参与者平均) 最高, 如论文中所述。LMDA-Net (Miao et al. (2023)) 是 2023 年发表的另一种轻量级解码网络, 在 BCI4-2A 和 BC

I4-2B 上的平均解码准确率 (参与者平均) 超过了 DRDA。值得注意的是, 在 2023 年之前发表的 BCI4-2A 和 BCI4-2B 中, Conformer (Song et al. (2023)) 被提及为表现最好的模型。然而, LMDA-Net 在 BCI4-2A 和 BCI4-2B 中展现出更高的平均分类准确率 (参与者平均), 使其成为解码能力的重要参考模型。

为了确保在 Weight-Freezing 的影响下, ConvNet、LMDA-Net 和 EEGNet 之间进行公正比较, Weight-Freezing 中的阈值 t 在整个实验中保持不变。具体而言, 并没有对阈值进行参与者特定的调整。这种方法最大程度上保证了不同模型之间的比较公平性, 并确保实验结果的可重复性。

5.3.2 BCI4-2A

表1展示了不同算法在 BCI4-2A 数据集上的分类性能。从表1中可以看出, 在 BCI4-2A 数据集上, Weight-Freezing 显著提高了所有实验模型的性能。特别值得注意的是, 当使用 Weight-Freezing 时, LMDA-Net 和 ConvNet 的平均分类准确率都超过了 81%。ConvNet 在使用 Weight-Freezing 时达到了令人印象深刻的 84.9% 的平均解码准确率。据我们所知, 这是目前该数据集中可实现的最高解码准确率 (参与者平均), 比 2020 年表现最佳的 DRDA 提高了 10.2%。Sinc-ShallowNet、EEGNet 和 LMDA-Net 都是轻量级网络, 并且根据实验结果, Weight-Freezing 不仅适用于参数较多的 ConvNet, 还适用于参数只有几千的 EEGNet 和 LMDA-Net。

从表1中还可以看出, EEGNet 在这个数据集中的解码能力并不占优势, 表现最差。然而, 通过应用 Weight-Freezing, EEGNet 的性能超过了 DRDA, 达到了 76.8% 的平均解码准确率。

表 1: 不同算法在 BCI4-2A 数据集上的分类表现

Methods	A01	A02	A03	A04	A05	A06	A07	A08	A09	mean \pm std
FBCSP+NBPW	76.0	56.5	81.2	61.0	55.0	45.2	82.7	81.2	70.7	67.7 \pm 13.7
ConvNet	76.4	55.2	89.2	74.6	56.9	54.1	92.7	77.1	76.4	72.5 \pm 14.2
EEGNet	75.3	51.0	88.5	57.3	46.5	50.3	83.7	80.5	87.1	68.9 \pm 17.4
Sinc-ShallowNet	-	-	-	-	-	-	-	-	-	72.8 \pm 12.9
DRDA	83.1	55.1	87.4	75.2	62.2	57.1	86.1	86.1	82.0	74.7 \pm 13.0
LMDA	86.5	67.4	91.7	77.4	65.6	61.1	91.3	83.3	85.4	78.8 \pm 11.5
EEGNet+WF(t=0.3)	78.8	70.5	94.8	63.5	67.0	55.9	87.8	82.6	89.9	76.8 \pm 13.2
LMDA+WF(t=0.4)	86.8	69.8	92.7	81.6	65.6	68.1	92.7	84.0	87.8	81.0 \pm 10.6
ConvNet+WF(t=0.3)	91.3	66.3	95.5	85.4	77.8	66.3	96.9	91.0	93.2	84.9 \pm 12.0

WF 表示应用了 Weight-Freezing, t 表示 Weight-Freezing 中的阈值。

所有使用 Weight-Freezing 的方法均进行了 800 个 epoch 的训练, 并记录了最佳准确率。其余方法的结果来自自己发表的论文。

Sinc-ShallowNet 每个参与者的具体性能未公开, 因此标记为“-”。

有关 Weight-Freezing 和全连接层之间的比较实验, 请参阅第6.1节。

表 2: 不同算法在 BCI4-2B 数据集上的分类表现

Methods	B01	B02	B03	B04	B05	B06	B07	B08	B09	mean \pm std
FBCSP+NBPW	70.0	60.3	60.9	97.5	93.1	80.6	78.1	92.5	86.8	80.0 \pm 13.9
ConvNet	74.3	56.0	57.5	97.5	95.3	82.1	79.6	87.5	86.5	79.6 \pm 14.8
EEGNet	77.5	61.0	63.1	98.4	96.5	83.7	84.3	92.8	88.4	82.9 \pm 13.5
DRDA	81.3	62.8	63.6	95.9	93.5	88.1	85.0	95.2	90.0	83.9 \pm 12.8
LMDA	81.6	63.6	72.8	98.1	96.3	90.3	85.3	95.0	89.7	85.5 \pm 12.0
ConvNet+WF(t=0.7)	80.0	56.1	61.9	97.8	92.2	89.4	84.1	93.1	88.8	82.6 \pm 14.4
LMDA+WF(t=0.9)	82.5	63.2	71.9	98.4	94.7	88.1	85.9	94.4	92.8	85.8 \pm 11.5
EEGNet+WF(t=0.8)	81.3	67.1	75.6	98.1	94.1	87.5	87.5	95.9	91.3	86.5 \pm 10.2

WF 表示应用了 Weight-Freezing, t 表示 Weight-Freezing 中的阈值。

所有使用 Weight-Freezing 的方法均进行了 800 个 epoch 的训练, 并记录了最佳准确率。其余方法的结果来自自己发表的论文。

当然, EEGNet 和 ConvNet 在分类性能上的显著提升不仅仅是由于 Weight-Freezing。以 ConvNet 为例, 除了分类网络, 带有 Weight-Freezing 的 ConvNet 还与原始 ConvNet 论文存在差异, 例如试验中一次试验的采样点数、数字滤波器、预处理方法和优化器等。

在比较的模型中, 与我们的实验设置最相似的是 LMDA-Net。然而, 值得注意的是, LMDA-Net 的原始论文进行了 300 个 epochs 的实验, 而我们在表1中的实验进行了 800 个 epochs。此外, 在我们的实验中, 每个试验中的采样点数从 LMDA-Net 中的原始 1125 个点减少到了 1000 个点。

在第6节中, 我们进行了比较实验, 以研究 Weight-Freezing 和全连接对每个参与者的分类准确率的影响。然而, 从实验结果来看, EEGNet、LMDA-Net 和 ConvNet 在应用 Weight-Freezing 后的分类性能显著提高。这些模型在分类性能上明显优于已知模型, 这表明 Weight-Freezing 是一种比全连接网络更适合的分类技术。EEGNet、LMDA-Net 和 ConvNet 从 Weight-Freezing 中获益的事实表明, Weight-Freezing 是一种通用的分类技术, 可以有效应用于各种类型的人工神经网络。

表 3: 不同算法在 High-Gamma 数据集上的分类表现

Methods	mean \pm std
FBCSP+rLDA	86.0 \pm 9.0
EEGNet	88.5 \pm 11.0
DeepConvNet	88.4 \pm 8.8
ConvNet	93.9 \pm 9.3
Sinc-ShallowNet	91.2 \pm 9.1
LMDA+WF($t=0.3$)	93.6 \pm 5.8
EEGNet+WF($t=0.3$)	94.0 \pm 4.6
ConvNet+WF($t=0.5$)	96.9 \pm 2.4

WF 表示应用了 Weight-Freezing 技术, t 表示 Weight-Freezing 中的阈值。

所有使用 Weight-Freezing 的方法都经过了 800 个 epochs 的训练, 并记录了最佳准确率。其余方法的结果来自于已发表的论文。

5.3.3 BCI4-2B

我们进一步验证了不同算法在 BCI4-2B 数据集上的分类性能。从表2中可以看出, 在 BCI4-2B 数据集上, 各个算法的分类性能变化不如在 BCI4-2A 上显著。在这个数据集中, 参数较多的 ConvNet 并没有优势。使用 Weight-Freezing 后, ConvNet 在这个数据集上的平均分类准确率为 82.6%, 低于与 ConvNet 具有类似特征提取网络的 DRDA。

在应用 Weight-Freezing 后, LMDA-Net 和 EEGNet 分别达到了 85.8% 和 86.5% 的平均分类准确率。据我们所知, 这些结果在这个数据集的分类性能方面超过了以前的最先进算法。

一个有趣的现象是, 在 BCI4-2B 中, 为了获得更好的分类结果, Weight-Freezing 中的阈值要比在 BCI4-2A 中大得多。ConvNet 和 EEGNet 的 Weight-Freezing 阈值都为 0.7, 意味着在全连接层中有 70% 的权重被冻结, 即在特定的运动想象任务的决策过程中, 只有少数输入神经元参与其中。这可能是在信噪比低、数据量较小的情况下的一种折中方案, 因为在当前有限的数据库中很难区分噪声和真实有效的特征。在这种情况下, 让某个类别的决策过程只考虑一小部分输入神经元可以帮助消除噪声的干扰。

尽管 BCI4-2B 与 BCI4-2A 是完全不同的 EEG 数据集, 但 EEGNet、LMDA-Net 和使用 Weight-Freezing 的 ConvNet 的分类性能都表现出了改进。这表明 Weight-Freezing 技术不仅在不同的 ANN 模型之间展现出很强的鲁棒性, 也在不同的 EEG 数据集上展现出了鲁棒性。

5.3.4 High-Gamma

Weight-Freezing 在前面提到的运动想象数据集上展现出了出色的性能。这种成功可以归因于运动想象信号的非平稳性和低信噪比。我们进一步评估了 Weight-Freezing 在运动执行 EEG (ME-EEG) 上的分类性能。High-Gamma 数据集包括四类运动执行任务, 每个参与者的训练数据量明显大于 BCI4-2A 和 BCI4-2B 的数据量。由于没有现有工作提供了 High-Gamma 数据集上每个参与者的详细分类性能, 我们只展示了所有参与者的平均准确率和标准差。有关每个参与者的详细分类性能的分析, 请参阅附录。

从表3可以看出, ME 解码要比 MI 解码更容易。FBCSP+rLDA 在四分类任务中达到了 86% 的平均准确率。Weight-Freezing 在 High-Gamma 上也奏效, LMDA-Net、EEGNet 和 ConvNet 在 Weight-Freezing 的提升下都超过了 93% 的分类准确率。其中, ConvNet 在应用 Weight-Freezing 后的性能达到了 96.9%。据我们所知, 这也是目前在数据集上可以实现的最高分类准确率。这表明 Weight-Freezing 在具有更大训练样本量的 ME-EEG 上仍然有效。这再次证明了 Weight-Freezing 是一种适用于 EEG 解码的合适分类网络。

6 分析

在本节中,我们以具有挑战性的 BCI4-2A 数据集为例,对 Weight-Freezing 进行了深入分析。我们采用了控制变量的方法,研究了在 ConvNet、EEGNet 和 LMDA-Net 三个模型中应用 Weight-Freezing 前后性能差异。在第6.1节中,我们提供了在应用 Weight-Freezing 前后的不同算法之间的性能曲线综合比较,揭示了不同算法在每个参与者下的测试准确率和训练轮次。在第6.2节中,我们检查了 Weight-Freezing 对输入 EEG 数据的采样点数量的鲁棒性。此外,在第6.4节中,我们扩大了 EEG 样本数量,并采用迁移学习来验证 Weight-Freezing 在大样本量下的鲁棒性。最后,在第6.5节中,我们分析了 Weight-Freezing 中阈值对准确性的影响。

6.1 应用 Weight-Freezing 前后的训练过程分析

尽管第5.3节中展示了应用 Weight-Freezing 后不同算法的测试准确率,但它只展示了我们方法在解码方面的优越性,无法具体反映 Weight-Freezing 应用前后训练过程的变化。因此,在本小节中,我们固定所有实验条件,详细比较了 Weight-Freezing 应用前后不同算法之间的差异。

从图3可以看出,几乎对于每个参与者和每个算法来说,在应用 Weight-Freezing 后,解码性能显著提高。这种解码准确率的提高不是由于大幅度波动,而是因为 ANN 模型确实获得了有效的训练。这表明,在相同的训练轮次下,应用 Weight-Freezing 后的 ANN 模型表现出更好的性能。此外,从图3中几乎所有参与者和所有测试的 ANN 模型的结果可以看出,这种观察结果是一致的。

ANN 模型在训练过程中的大幅波动是许多学者仍然倾向于将 FBCSP 作为特征提取方法的一个重要原因。由于训练数据量小且 EEG 的非平稳性,如果将训练数据重新划分为训练集和验证集,不仅模型的性能会因为训练集数据减少而降低,而且验证集中的数据分布可能与测试数据分布差异很大。这意味着在 EEG 解码中使用早停策略是非常困难的,因为 ANN 模型在验证集中的损失和准确率并不能直观地反映测试集中的情况。如果 ANN 模型在特定数量的训练轮次中能够实现良好且稳定的性能,这对于 BCI 系统的实际应用将非常有价值。

从图3可以看出,在大约 200 个训练轮次之后,不同模型在所有参与者中的测试准确率远远超过了 FBCSP+NBPW 的表现。ConvNet 和 LMDA-Net 甚至在不到 100 个训练轮次的情况下,就远远超过了 FBCSP+NBPW 的分类性能。从 400 到 800 个轮次期间不同模型的中位数测试准确率可以看出,在 Weight-Freezing 的提升下,ANN 模型在所有参与者的分类性能中已经与 FBCSP+NBPW 拉开了巨大的差距,从而证明 Weight-Freezing 技术是提高 ANN 解码能力的关键技术。

6.2 采样时间长度在 EEG 试验中的鲁棒性

在我们之前的研究中 (Miao et al. (2022, 2023)),我们一直假设 Schirrmeister et al. (2017) 提出的时间域数据截断方法是最佳的,即从运动想象或执行开始的 0.5 秒截断时间域数据。在本小节中,我们验证了 ANN 模型在应用 Weight-Freezing 前后对每个试验中不同时间域数据长度的鲁棒性。在本实验中,我们关注任务期间持续时间对测试结果的影响,不考虑由于降采样采样频率而导致的数据长度的变化。

在图4中,L=1000 表示每个试验选择了完整的 4 秒数据作为运动想象任务期间的数据,L=750 表示每个试验仅选择了运动想象任务期间的前三秒数据,L=1125 表示每个试验不仅包含了完整的运动想象任务期间的数据,还包括任务期间前 0.5 秒的数据。从图4中可以看出,应用 Weight-Freezing 后,EEGNet、ConvNet 和 LMDA-Net 几乎都达到了最高的平均准确率,表明 Weight-Freezing 在这种情况下表现出良好的鲁棒性,并且可以作为通用的分类网络。然而,在最后 10 个轮次的平均准确率中,应用 Weight-Freezing 对 ANN 模型的测试波动没有带来显著的改进,特别是对于 ConvNet 而言。ConvNet 在训练过程中观察到的波动与 Weight-Freezing 无关,而主要受到网络架构本身的影响。从图4中可以观察到,与 ConvNet 相比,LMDA-Net 和 EEGNet 的分类性能在不同情景下的波动较小。Weight-Freezing 作为一个分类网络,可以增强 ANN 模型的解码能力,但它对模型预测波动的改善能力是有限的。ANN 模型的预测波动主要由网络架构本身决定。

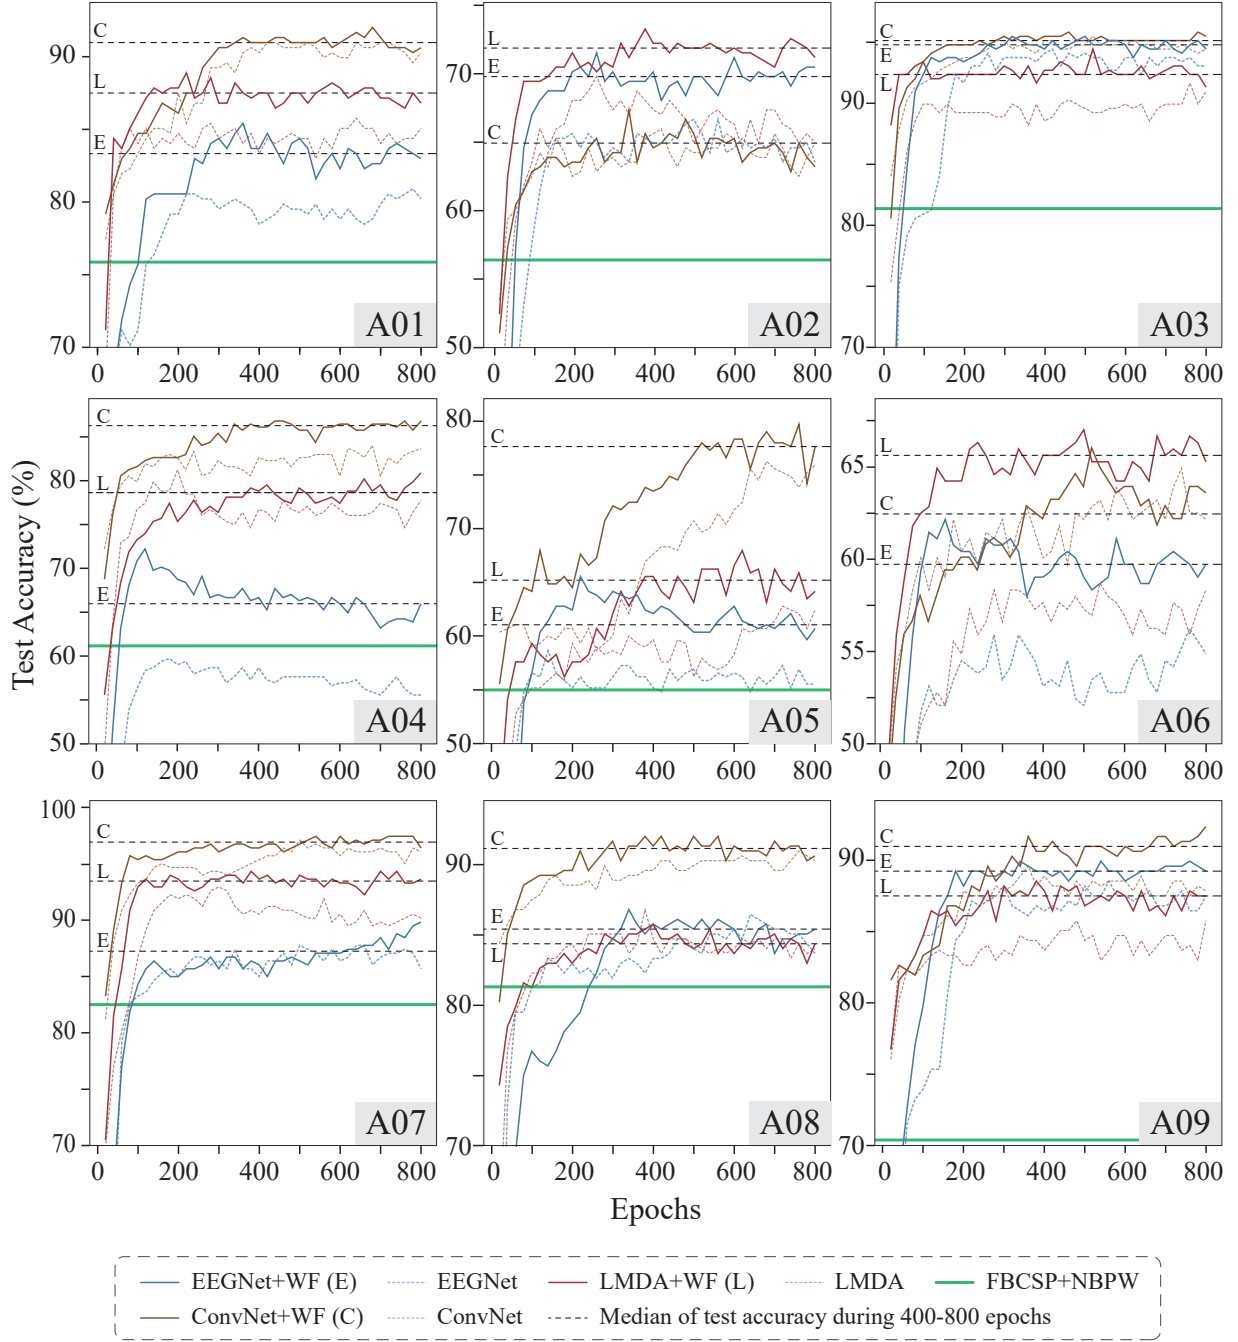


图 3: EEGNet、ConvNet 和 LMDA 在 BCI4-2A 数据集上 Weight-Freezing 前后的训练过程对比。为了清晰地展示不同模型的测试结果,对 ANN 模型的测试准确率应用了一个宽度为 20 的平滑窗口。图中还显示了应用 Weight-Freezing 后上述模型从第 400 个到第 800 个 epoch 的中位数测试准确率。FBCSP+NBPW 在 A06 上的分类准确率不到 50%, 因此未显示。

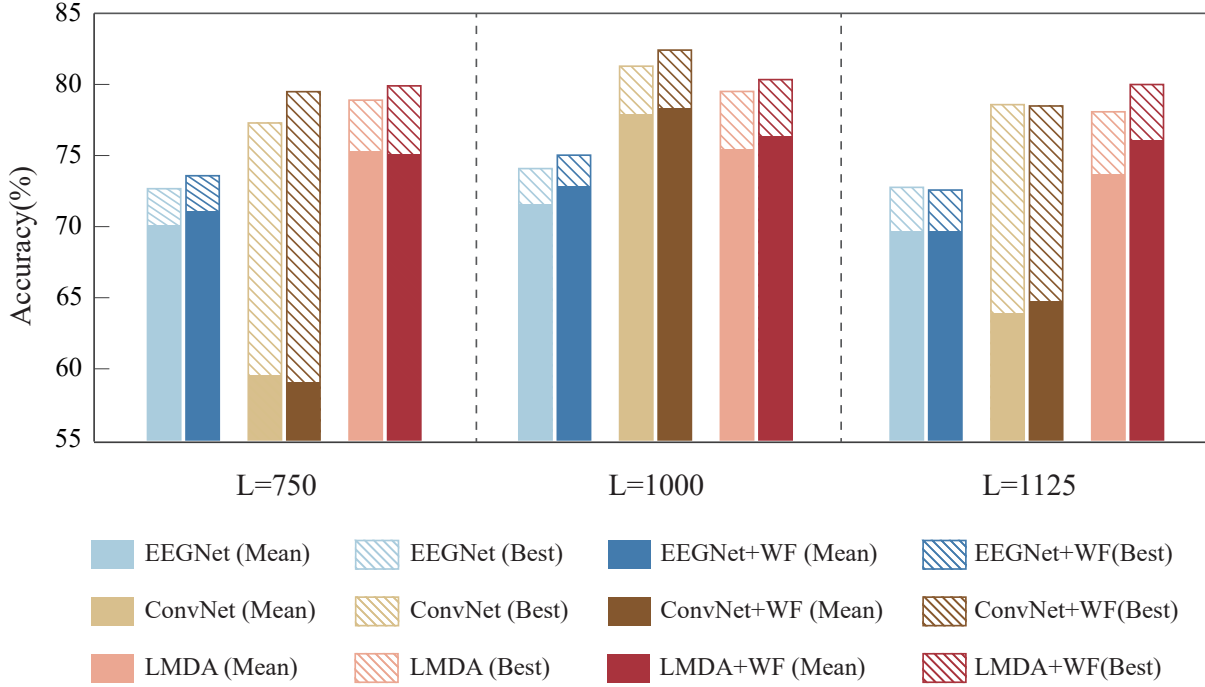


图 4: 在 BCI4-2A 数据集上, ANN 模型对 EEG 试验中采样时长的稳健性分析, 在应用 Weight-Freezing 之前和之后。所有的 ANN 模型均进行了 300 个 epoch 的训练, 并记录了所有参与者的平均准确率。阴影柱表示 ANN 模型的最高准确率, 而不透明实心柱表示最后 10 个 epoch 的平均准确率。(最佳效果请使用彩色图像查看)

如果将完整的运动想象任务期间作为基准, 即 $L=1000$ 是标准的试验长度, $L=750$ 和 $L=1125$ 反映了两种不同的情景: 缺失时间域数据和向时间域数据添加噪声。不同算法在这三种不同情景下的分类性能值得深入讨论。在这三种不同情景下, ConvNet 可以实现高分类准确率, 但其对于不同情景的预测波动也是最大

的。这表明 ConvNet 的参数受到微小扰动时, 决策结果会产生较大的差异, 这是 EEG 解码中不希望出现的特性。一个可能的原因是 ConvNet 具有太多的可学习参数, 只有几百个训练样本无法有效训练它们。尽管应用 Weight-Freezing 后 ConvNet 的解码能力略有改善, 但它仍然无法应对训练过程中特征提取网络的波动。EEGNet 和 LMDA-Net 等轻量级网络在这三种情景下具有相对稳定的分类性能, 应用 Weight-Freezing 也在一定程度上提高了它们的解码能力。轻量级网络本身的实现中融入了强大的正则化方法, Weight-Freezing 的使用可以视为额外的正则化过程。这突显了正则化技术在 EEG 解码中的重要性。在 $L=750$ 和 $L=1125$ 的情景中比较不同模型的性能, 发现在 $L=750$ 的情景下, 即使舍弃了任务期间的 25% 有效数据, 模型的性能也不低于 $L=1125$ 时的性能。与 $L=1125$ 的情景相比, $L=750$ 的情景本身也是一种正则化。不同模型在 $L=750$ 的情景中的分类性能也对运动想象实验的设计者提出了一个问题: 我们真的需要如此长的任务期间吗?

6.3 对训练数据量的鲁棒性

6.4 Weight-Freezing 在大样本量下的鲁棒性分析

在 EEG 解码中, 训练数据的不足是一个重要的挑战。在 BCI4-2A 中, 每个参与者只有 288 个训练样本, 而 EEGNet、LMDA-Net 和 ConvNet 的参数数量分别为 3012、4284 和 47364。在如此小的训练样本数量下, ANN 模型很容易出现过拟合。因此, 对 ANN 模型实施正则化非常重要, 这也是 Weight-Freezing 有效的一

表 4: 不同算法在 BCI4-2A 数据集上迁移学习的分类表现

Methods	A01	A02	A03	A04	A05	A06	A07	A08	A09	mean+std
DRDA	69.5	26.7	82.5	41.3	27.6	32.4	49.6	76.5	70.1	52.9+22.1
EEGNet	77.1	47.9	78.1	45.8	44.8	52.8	66.3	63.9	63.9	60.1+12.8
ConvNet	82.6	42.0	85.8	53.1	48.3	49.7	51.0	77.8	75.7	62.9+17.1
LMDA	78.5	44.4	80.6	49.3	46.2	47.9	56.3	76.7	73.3	61.5+15.4
EEGNet+WF($t=0.5$)	78.8	45.1	83.3	53.8	46.9	49.7	68.1	69.8	66.3	62.4+14.1
LMDA+WF($t=0.2$)	77.4	42.0	80.9	52.4	50.7	52.1	58.7	77.8	75.3	63.0+14.8
ConvNet+WF($t=0.2$)	81.9	41.3	84.4	54.9	51.7	51.0	53.1	77.8	75.7	63.5+16.2

WF 表示应用了 Weight-Freezing, t 表示 Weight-Freezing 中的阈值。

除了 DRDA 在已发表的论文中公开的结果外, 所有其他应用 Weight-Freezing 的方法均进行了 300 个 epoch 的训练, 并记录了最佳准确率。

一个重要原因。然而, 一个问题随之而来: 如果有充足的训练样本, Weight-Freezing 是否仍然有效? 不幸的是, 目前还没有公开可用的具有成千上万个样本的 EEG 数据集。因此, 我们有两种方法来增加训练样本数量, 第一种是数据增强, 第二种是迁移学习。考虑到人工生成的 EEG 数据与真实信号之间的差异和不确定性, 我们采用迁移学习来研究训练数据量对 Weight-Freezing 的影响。

基于迁移学习的测试可以被视为无监督学习。我们仅从目标参与者中选择测试数据, 并将所有其他参与者的数据用于训练。也就是说, 如果每个参与者有 288 个训练和测试数据, 在本节中的实验测试数据仍然为 288 个, 但训练数据为 $288 \times 2 \times 8$, 共计 4608 个。这个数据量几乎与 EEGNet 和 LMDA-Net 的参数数量相匹配。由于 Zhao et al. (2020) 也在相同的情景中进行了实验, 表4还显示了 DRDA 的测试准确率。从表4中可以看出, EEGNet、ConvNet 和 LMDA-Net 的平均分类准确率远高于 DRDA, 这表明在无监督学习中使用 GAN (Goodfellow et al. (2020)) 方法来减小目标参与者与其他参与者之间的数据分布差异是没有意义的。尽管无监督学习中的训练数据量与 EEGNet 和 LMDA-Net 的参数数量相当, 但所有模型在分类性能上并没有明显优势。这可能是因为真实的 EEG 信号是非平稳的, 并且具有较低的信噪比。因此, EEG 信号中的噪声不可避免地影响了解码准确性。从表4中还可以看出, Weight-Freezing 可以在一定程度上提高 ANN 模型的性能, 这表明它在训练数据量更大的迁移学习场景中也是适用的。

6.5 Weight-Freezing 中国阈值的影

Weight-Freezing 中的阈值代表完全连接层中被冻结的参数的比例。阈值越大, 完全连接层中被冻结的参数就越多。因此, 我们进一步验证了阈值 t 对不同 ANN 模型分类结果的影响。我们从集合 $\{0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8\}$ 中选择不同的阈值 t , 分别训练 ConvNet、EEGNet 和 LMDA-Net (运行 800 个 epochs), 并绘制不同阈值下每个模型所有参与者的平均准确率, 如图5所示。

从图5可以看出, LMDA-Net 和 ConvNet 对阈值的敏感性趋势相似, EEGNet 在 $t=0.7$ 时除外。对于 ConvNet, 当 $t=0.3$ 时, 它具有最佳的分类性能, 在 BCI4-2A 上的平均准确率为 84.9%。对于 LMDA-Net, 当 $t=0.4$ 时, 它具有最佳的分类性能, 平均准确率为 81.0%, 而 EEGNet 在 $t=0.2$ 和 0.3 时具有相同的分类性能, 均为 76.8%。从图5可以看出, 较大的阈值会影响模型的性能。当 $t>0.5$ 时, ConvNet 和 LMDA-Net 的分类准确率显著下降, 而当 $t>0.4$ 时, EEGNet 的分类准确率也显著下降 (除了 $t=0.7$ 的异常值)。阈值 t 对分类结果的影响也符合神经科学的先验知识, 即在特定类别的决策过程中, 并不需要考虑所有输入神经元。在特定类别的决策过程中, 忽略一些神经元的影响对于 EEG 特征分类是有意义的。根据 ANN 架构和解码任务选择适当的阈值可以充分发挥不同解码网络的优势, 从而提高 EEG 的解码分类性能。




图 5: 不同 ANN 模型在 BCI4-2A 数据集上的 Weight-Freezing 阈值对分类性能的影响。所有模型都经过 800 个 epochs 的训练, 记录了所有参与者的平均准确率。

7 结论与展望

7.1 结论

本文提出了一种增强 ANN 在 EEG 解码中分类性能的新方法。我们的方法称为 Weight-Freezing, 基于 ANN 正则化原则和神经科学先验知识。Weight-Freezing 通过利用掩码矩阵和阈值在完全连接层中冻结特定的权重, 从而减少了某些神经元对特定 EEG 任务决策过程的影响。通过将掩码权重设置为零, Weight-Freezing 在完全连接层实现了稀疏连接, 有效地作为一种正则化方法。我们使用三种不同的 ANN 架构和三个广泛引用的 EEG 数据集进行了实验。结果表明, Weight-Freezing 显著提高了三种 ANN 模型的分类性能, 并超过了这三个数据集上先前的最高平均准确率。在分析部分, 我们进行了对照实验, 比较了不同模型在 Weight-Freezing 前后的差异, 并研究了 Weight-Freezing 中阈值对分类结果的影响。我们的研究结果突出了 Weight-Freezing 作为 EEG 特征分类网络架构相对于传统的完全连接网络的优越性。这一方法在未来的研究中有潜力做出重要贡献。

7.2 展望

本文介绍了 Weight-Freezing 作为完全连接层正则化方法在 EEG 解码中的应用。尽管当前的研究主要集中在其在 EEG 解码中的有效性上, 但我们认为 Weight-Freezing 在其他领域也具有更广泛的应用。作为一种通用的正则化技术, Weight-Freezing 能够在完全连接层实现稀疏连接, 这使其与 Dropout 等传统方法有所区别。我们推测它的应用可能超越 EEG 解码, 在其他领域做出重要贡献。此外, 我们的研究在特定的 ANN 网络范围内验证了 Weight-Freezing 的性能, 主要是基于卷积网络的网络。鉴于 Transformer 网络在机器视觉和自然语言处理等领域取得的成功, 我们认为在 Transformer 网络的完全连接层中探索 Weight-Freezing 的

表 5: 不同算法在 High-Gamma 数据集中的详细分类表现

Methods	S01	S02	S03	S04	S05	S06	S07	S08	S09	S10	S11	S12	S13	S14
LMDA+WF ($t=0.3$)	96.9	90.0	99.4	100.0	96.3	90.0	92.5	91.9	98.1	92.5	76.9	95.6	93.1	96.9
EEGNet+WF ($t=0.3$)	90.6	93.8	100.0	99.4	95.0	93.8	91.8	96.3	99.4	89.4	91.9	96.9	95.6	83.1
ConvNet+WF ($t=0.5$)	95.0	95.6	100.0	100.0	98.8	96.9	94.3	95.0	98.8	95.6	98.1	98.1	98.7	91.9

WF 表示应用了 Weight-Freezing 技术, t 表示 Weight-Freezing 中的阈值。

所有的 ANN 模型都经过了 800 个 epochs 的训练, 并记录了最佳准确率。

研究是未来研究的一个有前景的方向。我们未来的工作将致力于研究在基于 Transformer 模型的 EEG 解码中 Weight-Freezing 的性能。我们相信这个方向具有巨大的潜力, 可以进一步提高我们对 Weight-Freezing 能力的理解, 并拓宽其应用范围。

附录

表5中列出了在应用 Weight-Freezing 后, ConvNet、EEGNet 和 LMDA-Net 在 High-Gamma 数据集中对每个参与者的分类性能。‘

统计和可重现性

我们在所有实验中使用了保留测试集的方法, 并固定了所有初始化种子, 以确保从神经网络模型获得的结果的可重现性。本研究使用的超参数没有针对每个参与者进行个别优化, 而是基于所有参与者的平均准确率进行设置。具体而言, 对于每个分类场景, 相同的初始化参数应用于所有参与者。鉴于我们研究中观察到的个体差异很大, 我们计算了所有参与者的平均准确率和方差。

数据和代码可用性声明

支持本研究结果的原始 EEG 数据已在正文中进行了注释。请参考提供的脚注。

EEGNet、ConvNet 和 LMDA-Net 的源代码可以在以下网页上公开获取: <https://github.com/vlawhern/ar1-eegmodels>、<https://github.com/TNTLFreiburg/braindecode>和<https://github.com/MiaoZhengQing/LMDA-Code>。我们很高兴为 Weight-Freezing 提供公开的源代码, 可在<https://github.com/MiaoZhengQing/WeightFreezing>上找到。

作者贡献声明

苗政清: 概念化、方法论、正式分析、调查研究、可视化、原始草稿撰写; 赵美蓉: 监督、资金。

竞争利益声明

作者声明没有竞争利益。

致谢

我们向杨一苇对图表进行润色的贡献表示感谢。同时, 我们衷心感谢匿名评审人员对本文的有益反馈和宝贵建议, 对于提高本文质量起到了重要作用。

参考文献

- Acharya, U.R., Oh, S.L., Hagiwara, Y., Tan, J.H., Adeli, H., 2018. Deep convolutional neural network for the automated detection and diagnosis of seizure using eeg signals. *Computers in biology and medicine* 100, 270–278.
- Ahn, H.J., Lee, D.H., Jeong, J.H., Lee, S.W., 2022. Multiscale convolutional transformer for eeg classification of mental imagery in different modalities. *IEEE Transactions on Neural Systems and Rehabilitation Engineering* .
- Ang, K.K., Chin, Z.Y., Zhang, H., Guan, C., 2008. Filter bank common spatial pattern (fbcs) in brain-computer interface, in: 2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence), IEEE. pp. 2390–2397.
- Ang, K.K., Chin, Z.Y., Zhang, H., Guan, C., 2011. Filter bank common spatial pattern (fbcs) algorithm using online adaptive and semi-supervised learning, in: The 2011 International Joint Conference on Neural Networks, IEEE. pp. 392–396.
- Bagchi, S., Bathula, D.R., 2022. Eeg-convtransformer for single-trial eeg-based visual stimulus classification. *Pattern Recognition* 129, 108757.
- Bejani, M.M., Ghatee, M., 2021. A systematic review on overfitting control in shallow and deep neural networks. *Artificial Intelligence Review* , 1–48.
- Borra, D., Fantozzi, S., Magosso, E., 2020. Interpretable and lightweight convolutional neural network for eeg decoding: Application to movement execution and imagination. *Neural Networks* 129, 55–74.
- DeVries, T., Taylor, G.W., 2017. Improved regularization of convolutional neural networks with cutout. *arXiv preprint arXiv:1708.04552* .
- Goncharova, I.I., McFarland, D.J., Vaughan, T.M., Wolpaw, J.R., 2003. Emg contamination of eeg: spectral and topographical characteristics. *Clinical neurophysiology* 114, 1580–1593.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., Bengio, Y., 2020. Generative adversarial networks. *Communications of the ACM* 63, 139–144.
- He, H., Wu, D., 2019. Transfer learning for brain-computer interfaces: A euclidean space data alignment approach. *IEEE Transactions on Biomedical Engineering* 67, 399–410.
- Kaplan, A.Y., Fingelkurts, A.A., Fingelkurts, A.A., Borisov, S.V., Darkhovsky, B.S., 2005. Nonstationary nature of the brain activity as revealed by eeg/meg: methodological, practical and conceptual challenges. *Signal processing* 85, 2190–2212.
- Lawhern, V.J., Solon, A.J., Waytowich, N.R., Gordon, S.M., Hung, C.P., Lance, B.J., 2018. Eegnet: a compact convolutional neural network for eeg-based brain-computer interfaces. *Journal of neural engineering* 15, 056013.
- Loshchilov, I., Hutter, F., 2018. Fixing weight decay regularization in adam URL: <https://openreview.net/forum?id=rk6qdGgCZ>.
- Lotte, F., Guan, C., 2010. Regularizing common spatial patterns to improve bci designs: unified theory and new algorithms. *IEEE Transactions on biomedical Engineering* 58, 355–362.
- Lotze, M., Halsband, U., 2006. Motor imagery. *Journal of Physiology-paris* 99, 386–395.
- Ma, W., Wang, C., Sun, X., Lin, X., Niu, L., Wang, Y., 2023. Mbga-net: A multi-branch graph adaptive network for individualized motor imagery eeg classification. *Computer Methods and Programs in Biomedicine* , 107641.

- Miao, Z., Zhang, X., Menon, C., Zheng, Y., Zhao, M., Ming, D., 2022. Priming cross-session motor imagery classification with a universal deep domain adaptation framework. *arXiv preprint arXiv:2202.09559* .
- Miao, Z., Zhao, M., Zhang, X., Ming, D., 2023. Lmda-net: a lightweight multi-dimensional attention network for general eeg-based brain-computer interfaces and interpretability. *NeuroImage* 276, 120209. URL: <https://www.sciencedirect.com/science/article/pii/S1053811923003609>, doi:<https://doi.org/10.1016/j.neuroimage.2023.120209>.
- Michel, C.M., Murray, M.M., 2012. Towards the utilization of eeg as a brain imaging tool. *Neuroimage* 61, 371–385.
- Park, W., Kwon, G.H., Kim, D.H., Kim, Y.H., Kim, S.P., Kim, L., 2014. Assessment of cognitive engagement in stroke patients from single-trial eeg during motor rehabilitation. *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 23, 351–362.
- Pfurtscheller, G., Brunner, C., Schlögl, A., Da Silva, F.L., 2006. Mu rhythm (de) synchronization and eeg single-trial classification of different motor imagery tasks. *NeuroImage* 31, 153–159.
- Pfurtscheller, G., Neuper, C., 2001. Motor imagery and direct brain-computer communication. *Proceedings of the IEEE* 89, 1123–1134.
- Santos, C.F.G.D., Papa, J.P., 2022. Avoiding overfitting: A survey on regularization methods for convolutional neural networks. *ACM Computing Surveys (CSUR)* 54, 1–25.
- Schirrneister, R.T., Springenberg, J.T., Fiederer, L.D.J., Glasstetter, M., Eggensperger, K., Tangermann, M., Hutter, F., Burgard, W., Ball, T., 2017. Deep learning with convolutional neural networks for eeg decoding and visualization. *Human brain mapping* 38, 5391–5420.
- Schwemmer, M.A., Skomrock, N.D., Sederberg, P.B., Ting, J.E., Sharma, G., Bockbrader, M.A., Friedenberg, D.A., 2018. Meeting brain-computer interface user performance expectations using a deep neural network decoding framework. *Nature medicine* 24, 1669–1676.
- Song, Y., Zheng, Q., Liu, B., Gao, X., 2023. Eeg conformer: Convolutional transformer for eeg decoding and visualization. *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 31, 710–719. doi:10.1109/TNSRE.2022.3230250.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R., 2014. Dropout: a simple way to prevent neural networks from overfitting. *The journal of machine learning research* 15, 1929–1958.
- Sterman, M.B., 1996. Physiological origins and functional correlates of eeg rhythmic activities: implications for self-regulation. *Biofeedback and Self-regulation* 21, 3–33.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I., 2017. Attention is all you need. *Advances in neural information processing systems* 30.
- Wager, S., Wang, S., Liang, P.S., 2013. Dropout training as adaptive regularization. *Advances in neural information processing systems* 26.
- Wolpaw, J.R., 2007. Brain-computer interfaces (bcis) for communication and control, in: *Proceedings of the 9th international ACM SIGACCESS conference on Computers and accessibility*, pp. 1–2.
- Wu, H., Gu, X., 2015. Towards dropout training for convolutional neural networks. *Neural Networks* 71, 1–10.
- Zhang, D., Li, H., Xie, J., 2023. Mi-cat: A transformer-based domain adaptation network for motor imagery classification. *Neural Networks* .

Zhao, H., Zheng, Q., Ma, K., Li, H., Zheng, Y., 2020. Deep representation-based domain adaptation for nonstationary eeg classification. *IEEE Transactions on Neural Networks and Learning Systems* 32, 535–545.